



07.09.2025

ON-PREM TOOL FOR AGENTIC RED TEAMING

Комплексно проводим аудит безопасности agentic-систем — внутри контура и до выхода в прод

MOROK проверяет безопасность компонентов agentic-системы, подтверждает находки изменениями наблюдаемого состояния и выявляет ключевые риски до релиза.

Для команд AI Security и MLSecOps в банках, юридических компаниях, госкорпорациях и других организациях с высокими требованиями к безопасности, хранению и работе с данными.

МОРОК наведём — уязвимости найдём.

Сегодня разработке и внедрению agentic-приложений уделяют больше внимания, чем обеспечению безопасности этих систем

02

01 • ВЗРЫВ ВНЕДРЕНИЯ

Agentic-системы входят в ключевые процессы

Платежи, клиентский сервис, продажи, HR и бэк-офис. Команды ускоряют внедрение, а безопасность остаётся вторым приоритетом.

БОЛЬШЕ РЕЛИЗОВ МЕНЬШЕ ВРЕМЕНИ

02 • LLM ВЫШЛА ИЗ ЧАТА

Теперь это автономная система, которая меняет состояние

Контекст, память, роли, инструменты и предыдущие действия влияют на следующее решение. Один вход не гарантирует один маршрут.

ПАМЯТЬ ПРАВА ИНСТРУМЕНТЫ
ДЕЙСТВИЯ

03 • АУДИТ СЕГОДНЯ

Безопасность таких систем по-прежнему доказывают вручную

Статические методы и анализаторы проверяют только заранее заданные условия; фиксированный сценарий — только знакомый путь. Эксперту приходится адаптивно исследовать систему вручную — **2–3 дня на одну проверку.**

ВРУЧНУЮ ДОРОГО НЕ УСПЕВАЕТ

КЛЮЧЕВАЯ ПРОБЛЕМА

Безопасность agentic-систем нельзя доказать статическими методами и анализаторами. Нужны адаптивные методы, которые изучают и проверяют систему в динамике.

Для критичных данных нужен адаптивный аудит в контролируемой среде

BASELINE 1 · РУЧНОЙ АУДИТ

Редкая экспертиза
не масштабируется

300–400 тыс. ₽

специалист MLSecOps / мес.

600–800 тыс. ₽

внешний аудит / проект

2–3 дня

техническая проверка
одной системы

36–66 тыс. ₽

себестоимость техпроверки
своими силами

BASELINE 2 · ФУНДАМЕНТАЛЬНАЯ МОДЕЛЬ + HARNESS

**OpenAI Codex
/ Claude Code**

\$100–200

Адаптивно исследует систему

в месяц на исследователя + переменный API usage.
Архитектура и контекст уходят во внешний сервис — для критичных данных это не рабочий вариант.

MOROK · ADAPTIVE AUDIT

Данные не покидают
контролируемую среду

ON-PREM · ЛОКАЛЬНЫЕ
МОДЕЛИ

ПРОВЕРОК В ГОД

×5

300 → 1 500

Та же команда из трёх
специалистов проверяет в пять
раз больше систем.

СЕБЕСТОИМОСТЬ
ТЕХПРОВЕРКИ

–80%

36–66 → 5–13 тыс. ₽

MOROK ведёт кампанию;
эксперт работает с
подтверждёнными находками.

ПОВТОР ПОСЛЕ РЕЛИЗА

до ×30

недели → минуты

Доказанная атака сохраняется
как regression-тест и
повторяется после изменений.

Адаптивные сценарии · проверка состояния · локальные модели · быстрый retest

LIVE DEMO • ОДИН АУДИТ ЦЕЛИКОМ

От архитектуры agentic-системы — до доказанной находки и повторного теста

АРТЕФАКТЫ ЦЕЛИ



ПРОФИЛЬ



КАМПАНИЯ АТАК



EVIDENCE



ОТЧЁТ + RETEST

Не экскурсия по вкладкам — путь специалиста к решению о риске.

ПЕРЕХОДИМ В ПРОДУКТ →

MOROK превращает описание системы в доказанный риск и готовый retest

ON-PREM · ВНУТРИ КОНТУРА ЗАКАЗЧИКА

Документация, данные проверок и отчёты не покидают периметр



Ценность Разрозненные артефакты → реальная поверхность → доказанный риск → повторяемый контроль

Продуктовый контур собран; экономику подтверждаем на пилоте

СДЕЛАНО

Полный workflow

Профиль → surface map → генерация → кампания → evidence → два отчёта → replay.

ПРОВЕРЕНО

4 / 4 ВАС

ASR 100% на одном намеренно уязвимом учебном стенде и одном классе атак.

ИНЖЕНЕРНАЯ БАЗА

493 теста · ОК

Последний подтверждённый snapshot проекта от 05.09.2026.

НАБЛЮДАЕМОСТЬ

19 spans

Живой W3C trace от запуска кампании до вызова инструмента.

НА ПИЛОТЕ ИЗМЕРЯЕМ

Время аудита от профиля до evidence-отчёта

Релевантность и false positives

Принятие finding командой продукта

Стоимость retest после релиза

ВКЛАД КОМАНДЫ

Иван — продукт · Даниил — ядро и кампании · Тамерлан — evidence, regression и отчётность

СЛЕДУЮЩИЙ ШАГ • 4 НЕДЕЛИ

Нужен design partner с реальной agentic-системой и авторизованным контуром

Цель пилота — заменить расчётную модель измеренным временем аудита, качеством evidence и стоимостью повторной проверки.

СДЕЛАНО

Рабочий end-to-end workflow

ПРОВЕРЕНО

State evidence и воспроизводимый запуск

ДАЛЬШЕ

Первый evidence-отчёт по реальной agentic-системе

ФИНАЛЬНАЯ ФРАЗА • 10-15 СЕКУНД

MOROK превращает разовый ручной аудит в повторяемый on-prem процесс: больше проверенных agentic-систем, ниже себестоимость, быстрый retest. Рабочий контур уже собран; следующий шаг — четырёхнедельный пилот с design partner.

Три сегмента требуют одной технологии, но разной упаковки продукта

A1

СЕГМЕНТ 1

ВЫБРАН

Банки и организации с повышенными требованиями к ИБ

Покупатель: CISO / ДКБ.
Пользователь: AI Security и MLSecOps. Нужны закрытый контур, доказательства для риск-комитета и регулярный retest.

ФОРМАТ

On-prem инструмент во внутренней инфраструктуре

СЕГМЕНТ 2

Кибербез-компании, Red Team и интеграторы

Покупатель: руководитель практики.
Пользователь: пентестер. Ценность — больше проектов, единая методология и повторная проверка для клиентов.

ФОРМАТ

White-label / on-prem модуль для переиспользования и продажи

СЕГМЕНТ 3

Компании, создающие agentic-системы для своих процессов

Ритейл, e-commerce, телеком и B2B без зрелой AI Security-функции. Нужен понятный цикл проверки перед релизом.

ФОРМАТ

Managed-сервис: аудит, triage и retest после исправлений

Discovery превратился в три проверяемые гипотезы продукта

A2

H1

Автоматизация цикла увеличит ёмкость и снизит себестоимость аудита

Профиль → атаки → evidence → отчёт → retest.

ПРОВЕРЯЕМ

Время до отчёта, проверок на специалиста, стоимость triage и retest.

H2

State evidence повысит доверие к находке

Успех подтверждается изменением состояния, а не формулировкой ответа.

ПРОВЕРЯЕМ

Долю принятых findings, false positives и запуск исправления командой системы.

H3

Один отчёт поможет согласовать безопасность и полезность системы

Технический evidence связывается с бизнес-эффектом и ограничениями.

ПРОВЕРЯЕМ

Достаточность отчёта для решения: исправить, ограничить или принять риск.

MOROK соединяет on-prem, полный agentic-контур, state evidence и retest

A3

КРИТЕРИЙ	MOROK	HiveTrace Red	Кредо-С	PT / BI.ZONE	Pillar • Straiker • SPLX
Формат	Инструмент для эксперта	LLM / GenAI scanner	Аудит как услуга	Red Team как услуга	Agentic security platform
On-prem в РФ	Да	Частично / Enterprise	Да	Да, в проекте	Ограниченно или custom
Agentic-поверхность	Память, роли, tools, cross-session	Модель и диалог; память публично не раскрыта	Агенты и function calling вручную	Широкий ручной scope	Сильное agentic-покрытие
State evidence	Детерминированные проверки состояния	Не раскрыто для memory/tool state	Экспертные доказательства	Экспертные доказательства	Есть у части платформ
Replay / retest	Находка → regression-тест	Частично	Retest в рамках проекта	Повторный проект	Есть у части платформ
Сильная сторона / ограничение	Полный цикл; зрелость подтверждаем пилотом	91 атака, RU-модели; фокус на LLM	ФСТЭК и прозрачный прайс; не продукт	Экспертиза и банки; низкая повторяемость	Зрелые платформы; доступность контура

Сценарии связывают стандарт, поверхность цели, доказательство и retest

A4

КАТАЛОГ

Память: policy-conformant poisoning

ASI06 · memory write · cross-user

Память: cross-session effect

inject → persist → activate

Память → чужой tool call

ASI06 → ASI03 · principal mismatch

Обход доступа через tool arguments

ВАС · фактический аргумент вызова

Разведка системного промпта

текстовый сигнал · потолок indirect

01

Композиция

шаблон × профиль цели



02

Генерация payload

варианты доставки и многошаговые цепочки



03

Прогон + traces

ответы, tool calls, память, snapshots



04

State evidence

детерминированный verdict



05

Regression

та же атака после исправления

Три владельца закрыли продукт, campaign engine и evidence lifecycle

A5

ПРОДУКТ

Иван

Discovery, сегменты, ценность, UX и защита продукта.

ИНЖЕНЕРИЯ

Даниил

Ядро атак, оркестрация кампаний, генерация и интеграция с целью.

ИНЖЕНЕРИЯ

Тамерлан

State oracle, evidence, traces, regression и отчётность.

КАК ПРОЕКТИРУЕМ

Spec-driven development

Сначала сценарий, доказательство и границы — потом код. Каждая задача имеет владельца и критерий готовности.

Факт важнее мнения модели

LLM расширяет поиск атак; код подтверждает результат; человек интерпретирует риск.

ЧТО СДЕЛАЛА КОМАНДА

Единый campaign runner для CLI и UI

Профильная архитектура без target-specific кода в ядре

Evidence и lifecycle от finding до closed/reopened

Два отчёта — технический и бизнесовый

Даже пессимистичный сценарий увеличивает ёмкость команды в 2,5 раза

A6

СЦЕНАРИЙ	ЧАСОВ / СИСТЕМА	ПРОВЕРOK / ГОД	РОСТ ЁМКОСТИ	СЕБЕСТОИМОСТЬ
AS-IS	20 ч	300	—	36–66 тыс. ₺
Пессимистично	8 ч	750	×2,5	18–22 тыс. ₺
База	4 ч	1 500	×5	9–11 тыс. ₺
Оптимистично	2 ч	3 000	×10	5–6 тыс. ₺

Допущение: 250 рабочих дней; 3 специалиста; 18–22 тыс. ₺/человеко-день.

все T0-BE значения измеряем в пилоте

Шесть вопросов, на которые отвечаем за 30 секунд

A7

ПОЧЕМУ НЕ ГОТОВОЕ РЕШЕНИЕ?

Prompt-scanners не видят полный lifecycle памяти и tool arguments; зарубежный SaaS не подходит закрытому контуру; услуга плохо повторяется после каждого релиза.

СКОЛЬКО СТОИТ?

Цену MOROK не называем до пилота. Сначала измеряем compute, поддержку профиля и время triage. 400–800 тыс. ₽ — якорь ручной альтернативы, не наш прайс.

ЧТО С ДАННЫМИ?

On-prem: документация, traces и отчёты остаются внутри компании. Активные атаки идут только на авторизованный подготовленный контур с синтетическими данными.

КТО ПОДДЕРЖИВАЕТ?

MOROK поддерживает ядро и каталог; команда заказчика владеет профилем цели и принимает решение по риску. Новый класс цели может потребовать адаптер.

ЧТО ЕСЛИ МЕТРИКА УПАДЁТ?

ASR не оцениваем отдельно: смотрим покрытие, разнообразие, ошибки и штатный сценарий. Падение может означать исправление, деградацию генератора или потерю evidence — причины разделены.

КТО ЗА ЧТО ОТВЕЧАЕТ?

Иван — продукт и экономика. **Даниил** — campaign engine и интеграция. **Тамерлан** — evidence, regression и отчёт.