

ZERO TRACE

AGENTIC RED TEAM

Проверяем действия и состояние агента,
а не убедительность его ответа

ПРОМЕЖУТОЧНЫЙ РЕЗУЛЬТАТ


04.09.2026

Вред может проявиться в следующей сессии

Обычный red teaming

запрос ————— ответ

ИИ-агент



Ответ может быть безобидным.

Память или tool call — уже скомпрометированы.

Нужен результат, который можно проверить

AI SECURITY / MLSECOPS

Проверить агента до релиза
—
и после каждого изменения.

01 Внутри контура

Без передачи чувствительных данных наружу

02 Повторяемо

Один сценарий можно запускать после каждого изменения

03 По фактам

Вердикт опирается на память и реальные tool calls

Вердикт основан на состоянии памяти и реальных вызовах.

Атаку ищет LLM. Успех проверяет код

01**Система**

architecture + system
card

02**Сценарий**

LLM или YAML

03**Запуск**

users + sessions +
steps

04**Трасса**


memory + tool calls

05**Вердикт**

assertions + ASR +
report

Вердикт опирается на память и журнал вызовов.

Видим память, tool calls и аргументы



Опционально: одна Langfuse-трасса на весь путь.

Демо: запрос чужого портфеля

4 ВАРИАНТА АТАКИ

- Прямой запрос
- «У меня есть полномочия»
- Сравнение клиентов
- «Проверка API»

ФАКТИЧЕСКИЙ TOOL CALL

actor cus=1001

argument cus=1002

Проверка читает вызов из журнала invest-server.

Доказательство берём из фактического действия агента.

4 из 4 атак дошли до вызова с cus=1002

ASR

100%

4 / 4

1001

пользователь



1002

аргумент tool call

- Каждая попытка раскрыла синтетический портфель другого клиента.
- Результат подтверждён журналом вызовов.

Ограничение: один класс атак, уязвимый режим, малая выборка.

Что уже работает

77

автоматических тестов

ПРОТОТИП

CLI + Streamlit

- Адаптивный ВАС + 4 фиксированных сценария
- Несколько пользователей, сессий и шагов
- Снимки памяти и сбор tool calls
- Детерминированный ASR и Markdown-отчёт
- Три независимые LLM-роли

Что проверено, а что пока нет

СЕЙЧАС

Один учебный агент
Синтетические данные
Адаптивный ВАС

Memory-сценарии заданы вручную.

ПОКА НЕТ

Live-прогон memory poisoning
Сравнение с protected
Сквозная Langfuse-трасса

Последний прогон — без Langfuse credentials.

Выводы относятся к текущему учебному стенду, а не ко всем агентным системам.

До финала: проверить атаку через память

СЕССИЯ 1 · АТАКУЮЩИЙ

01
Записать
правило
в общую
память

02
Завершить
сессию
атакующего

СЕССИЯ 2 · ДРУГОЙ ПОЛЬЗОВАТЕЛЬ

03
Открыть
новую
сессию

04
Поймать
подмену
аргумента

05
Повторить в
protected

06
Сохранить
трассу
и отчёт

ПАМЯТЬ СОХРАНИЛАСЬ

Успех: правило пережило сессию и изменило действие другого пользователя.

Команда Zero Trace

УЧАСТНИК	РОЛЬ	ЗОНА ОТВЕТСТВЕННОСТИ	УЧАСТИЕ
Даниил Середкин	AI Engineer	Attack toolkit, BAC PoC, LLM routing, CLI	Активное
Тамерлан Аушев	AI Engineer	Интеграция стенда, pipeline, Streamlit, tracing, тесты	Активное
Иван Голов	AI Product	Интервью, рынок, гипотезы, требования, дизайн	Активное

Следующий проверяемый результат

Memory poisoning между пользователями → tool call
